

Рубежный контроль №1

Тема: Методы обработки данных

Выполнил: Ханунов Г.И Группа: ИУ5-23М

Вариант: 10

Задачи: 10 и 30

Загрузка и первичный анализ данных

Для выполнения работы используется набор данных **Penguins** из библиотеки **seaborn**.

Описание признаков:

- **species** — вид пингвина;
- **island** — остров, на котором проводилось наблюдение;
- **bill_length_mm** — длина клюва, мм;
- **bill_depth_mm** — глубина клюва, мм;
- **flipper_length_mm** — длина плавника, мм;
- **body_mass_g** — масса тела, г;
- **sex** — пол пингвина.

В признаке **sex** есть пропущенные значения, поэтому используем это для 10. Для 30 в копию набора данных будут добавлены повторяющиеся признаки, после чего они будут найдены и удалены.

```
# Импорт библиотек
from pathlib import Path
import os

# Настройка локального кэша matplotlib внутри проекта
os.environ["MPLCONFIGDIR"] = str((Path.cwd() / ".cache" /
"matplotlib").resolve())
Path(os.environ["MPLCONFIGDIR"]).mkdir(parents=True, exist_ok=True)

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

%matplotlib inline
sns.set_theme(style="whitegrid", palette="Set2")
plt.rcParams["figure.figsize"] = (10, 5)
pd.set_option("display.max_columns", 20)
```

```
# Загрузка датасета из локального кэша seaborn
data_home = Path("data")
df = sns.load_dataset("penguins", data_home=str(data_home))

print(f"Размер данных: {df.shape[0]} строк, {df.shape[1]} столбцов")
df.head(10)
```

Размер данных: 344 строк, 7 столбцов

	species	island	bill_length_mm	bill_depth_mm	flipper_length_mm
0	Adelie	Torgersen	39.1	18.7	181.0
1	Adelie	Torgersen	39.5	17.4	186.0
2	Adelie	Torgersen	40.3	18.0	195.0
3	Adelie	Torgersen	NaN	NaN	NaN
4	Adelie	Torgersen	36.7	19.3	193.0
5	Adelie	Torgersen	39.3	20.6	190.0
6	Adelie	Torgersen	38.9	17.8	181.0
7	Adelie	Torgersen	39.2	19.6	195.0
8	Adelie	Torgersen	34.1	18.1	193.0
9	Adelie	Torgersen	42.0	20.2	190.0

	body_mass_g	sex
0	3750.0	Male
1	3800.0	Female
2	3250.0	Female
3	NaN	NaN
4	3450.0	Female
5	3650.0	Male
6	3625.0	Female
7	4675.0	Male
8	3475.0	NaN
9	4250.0	NaN

```
df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 344 entries, 0 to 343
Data columns (total 7 columns):
#   Column              Non-Null Count  Dtype
---  -

```

```

0   species      344 non-null    str
1   island       344 non-null    str
2   bill_length_mm 342 non-null  float64
3   bill_depth_mm 342 non-null  float64
4   flipper_length_mm 342 non-null float64
5   body_mass_g   342 non-null  float64
6   sex          333 non-null    str

```

```
dtypes: float64(4), str(3)
```

```
memory usage: 18.9 KB
```

```

missing_summary = pd.DataFrame({
    "Тип данных": df.dtypes.astype(str),
    "Количество пропусков": df.isna().sum(),
    "Доля пропусков, %": (df.isna().mean() * 100).round(2),
})

```

```
missing_summary
```

	Тип данных	Количество пропусков	Доля пропусков, %
species	str	0	0.00
island	str	0	0.00
bill_length_mm	float64	2	0.58
bill_depth_mm	float64	2	0.58
flipper_length_mm	float64	2	0.58
body_mass_g	float64	2	0.58
sex	str	11	3.20

```
df.describe(include="all")
```


	species	island	bill_length_mm	bill_depth_mm
flipper_length_mm \				
count	344	344	342.000000	342.000000
unique	3	3	NaN	NaN
top	Adelie	Biscoe	NaN	NaN
freq	152	168	NaN	NaN
mean	NaN	NaN	43.921930	17.151170
std	NaN	NaN	5.459584	1.974793
min	NaN	NaN	32.100000	13.100000
25%	NaN	NaN	39.225000	15.600000
50%	NaN	NaN	44.450000	17.300000
75%	NaN	NaN	48.500000	18.700000

max	NaN	NaN	59.600000	21.500000
231.000000				

	body_mass_g	sex
count	342.000000	333
unique	NaN	2
top	NaN	Male
freq	NaN	168
mean	4201.754386	NaN
std	801.954536	NaN
min	2700.000000	NaN
25%	3550.000000	NaN
50%	4050.000000	NaN
75%	4750.000000	NaN
max	6300.000000	NaN


Построим диаграмму рассеяния для двух числовых признаков. Цветом обозначен вид пингвина.

```
plt.figure(figsize=(9, 6))
sns.scatterplot(
    data=df,
    x="bill_length_mm",
    y="flipper_length_mm",
    hue="species",
    style="species",
    s=75,
)
plt.title("Связь длины клюва и длины плавника")
plt.xlabel("Длина клюва, мм")
plt.ylabel("Длина плавника, мм")
plt.legend(title="Вид")
plt.tight_layout()
plt.show()
```



Построим «ящик с усами» для признака `body_mass_g`.

```
plt.figure(figsize=(8, 5))
sns.boxplot(data=df, y="body_mass_g", color="#72B7B2")
plt.title("Ящик с усами для признака body_mass_g")
plt.ylabel("Масса тела, г")
plt.tight_layout()
plt.show()
```



Задача №10: заполнение пропусков наиболее распространенным значением

Необходимо устранить пропуски в одном категориальном признаке методом заполнения наиболее распространенным значением. В качестве признака выбран sex.

```
df_task10 = df.copy()
feature = "sex"

missing_before = df_task10[feature].isna().sum()
most_common_value = df_task10[feature].mode(dropna=True).iloc[0]

print(f"Категориальный признак: {feature}")
print(f"Пропусков до обработки: {missing_before}")
print(f"Наиболее распространенное значение: {most_common_value}")

before_counts = df_task10[feature].fillna("Пропуск").value_counts()
before_counts.to_frame("Количество до обработки")
```

Категориальный признак: sex
Пропусков до обработки: 11
Наиболее распространенное значение: Male

Количество до обработки

sex	
Male	168
Female	165
Пропуск	11

```
# Заполнение пропусков наиболее распространенным значением
df_task10[feature] = df_task10[feature].fillna(most_common_value)
```

```
missing_after = df_task10[feature].isna().sum()
print(f"Пропусков после обработки: {missing_after}")
```

```
after_counts = df_task10[feature].fillna("Пропуск").value_counts()
counts_comparison = pd.concat(
    [before_counts.rename("До обработки"), after_counts.rename("После
обработки")],
    axis=1,
).fillna(0).astype(int)
counts_comparison
```

Пропусков после обработки: 0


	До обработки	После обработки
sex		
Male	168	179
Female	165	165
Пропуск	11	0

```
# Визуализация распределения категорий до и после заполнения
fig, axes = plt.subplots(1, 2, figsize=(12, 5), sharey=True)
order = counts_comparison.index.tolist()
```

```
sns.countplot(x=df[feature].fillna("Пропуск"), order=order,
ax=axes[0], color="#4C78A8")
axes[0].set_title("До обработки")
axes[0].set_xlabel(feature)
axes[0].set_ylabel("Количество")
```

```
sns.countplot(x=df_task10[feature].fillna("Пропуск"), order=order,
ax=axes[1], color="#F58518")
axes[1].set_title("После заполнения модой")
axes[1].set_xlabel(feature)
axes[1].set_ylabel("Количество")
```

```
plt.tight_layout()
plt.show()
```



Вывод по задаче №10. Пропуски в категориальном признаке `sex` заполнены значением, которое встречается чаще всего. После обработки количество пропусков равно нулю.

Задача №30: удаление повторяющихся признаков

Необходимо удалить признаки, которые полностью дублируют другие признаки набора данных. В исходном наборе таких признаков нет, поэтому для демонстрации в копию данных добавлены три повторяющихся столбца.

```
df_task30 = df.copy()
```

```
# Добавим повторяющиеся признаки
```

```
df_task30["bill_length_mm_copy"] = df_task30["bill_length_mm"]
```

```
df_task30["island_copy"] = df_task30["island"]
```

```
df_task30["body_mass_g_copy"] = df_task30["body_mass_g"]
```

```
print(f"Размер данных до удаления повторяющихся признаков:
```

```
{df_task30.shape}")
```

```
df_task30.head()
```

Размер данных до удаления повторяющихся признаков: (344, 10)

	species	island	bill_length_mm	bill_depth_mm	flipper_length_mm
0	Adelie	Torgersen	39.1	18.7	181.0
1	Adelie	Torgersen	39.5	17.4	186.0
2	Adelie	Torgersen	40.3	18.0	195.0
3	Adelie	Torgersen	NaN	NaN	NaN
4	Adelie	Torgersen	36.7	19.3	193.0

	body_mass_g	sex	bill_length_mm_copy	island_copy
body_mass_g_copy				
0	3750.0	Male	39.1	Torgersen
3750.0				
1	3800.0	Female	39.5	Torgersen
3800.0				
2	3250.0	Female	40.3	Torgersen
3250.0				
3	NaN	NaN	NaN	Torgersen
NaN				
4	3450.0	Female	36.7	Torgersen
3450.0				

Поиск повторяющихся признаков

```
original_columns = []
```

```
duplicate_pairs = []
```

```
for column in df_task30.columns:
```

```
    duplicate_for = None
```

```
    for original in original_columns:
```

```
        if df_task30[column].equals(df_task30[original]):
```

```
            duplicate_for = original
```

```
            break
```

```
    if duplicate_for is None:
```

```
        original_columns.append(column)
```

```
    else:
```

```
        duplicate_pairs.append({
```

```
            "Повторяющийся признак": column,
```

```
            "Дублирует признак": duplicate_for,
```

```
        })
```

```
duplicate_pairs_df = pd.DataFrame(duplicate_pairs)
```

```
duplicate_pairs_df
```

	Повторяющийся признак	Дублирует признак
0	bill_length_mm_copy	bill_length_mm
1	island_copy	island
2	body_mass_g_copy	body_mass_g

Удаление найденных повторяющихся признаков

```
duplicate_columns = duplicate_pairs_df["Повторяющийся  
признак"].tolist()
```

```
df_task30_clean = df_task30.drop(columns=duplicate_columns)
```

```
print(f"Удаленные признаки: {duplicate_columns}")
```

```
print(f"Размер данных после удаления повторяющихся признаков:  
{df_task30_clean.shape}")
```

```
removed_summary = pd.DataFrame({
    "Показатель": ["Количество признаков до", "Количество удаленных признаков", "Количество признаков после"],
    "Значение": [df_task30.shape[1], len(duplicate_columns), df_task30_clean.shape[1]],
})
removed_summary
```

Удаленные признаки: ['bill_length_mm_copy', 'island_copy', 'body_mass_g_copy']

Размер данных после удаления повторяющихся признаков: (344, 7)

	Показатель	Значение
0	Количество признаков до	10
1	Количество удаленных признаков	3
2	Количество признаков после	7

Проверка, что повторяющихся признаков больше нет

```
remaining_duplicates = []
checked_columns = []
```

```
for column in df_task30_clean.columns:
    duplicate_for = None
    for checked in checked_columns:
        if df_task30_clean[column].equals(df_task30_clean[checked]):
            duplicate_for = checked
            break

    if duplicate_for is None:
        checked_columns.append(column)
    else:
        remaining_duplicates.append((column, duplicate_for))
```

```
print(f"Повторяющихся признаков после обработки: {len(remaining_duplicates)}")
remaining_duplicates
```

Повторяющихся признаков после обработки: 0

```
[]
```

Вывод по задаче 30. Найдены и удалены признаки `bill_length_mm_copy`, `island_copy`, `body_mass_g_copy`, которые полностью повторяли исходные столбцы. После обработки повторяющихся признаков не осталось.